



南開大學
Nankai University

计算机学院
人工智能导论实验报告

论文阅读

姓名：林盛森 余俊辉 李泽昊
学号：2312631 2313486 2312594
专业：计算机科学与技术

2025 年 6 月 2 日

目录

1	Deep Residual Learning for Image Recognition	2
1.1	研究背景与动机	2
1.2	核心思想	2
1.3	网络架构设计	3
1.4	实验结果与对比分析	5
1.4.1	18 层和 34 层的普通网络比较	5
1.4.2	18 层和 34 层的残差网络比较	6
1.4.3	更深的残差网络——瓶颈结构	7

1 Deep Residual Learning for Image Recognition

1.1 研究背景与动机




图 1.1: Training error and test error with 20-layer and 56-layer “plain” networks.

随着深度学习的发展，神经网络越来越深。然而，作者发现：一味地堆叠更多的层，反而导致网络性能下降，这被称为“退化问题”（degradation problem）。具体表现为：更深的网络不仅在训练集上误差更高，甚至比浅层网络表现更差。需要注意的是：这种现象不是“过拟合”（在训练集和测试集上表现都很差），而是深层网络在训练中优化困难，梯度无法有效传播，无法学得有效的表示。

故作者在论文中提出以下两个问题：

- 是否可以构建极深的神经网络而不会出现训练退化？
- 能否找到一个机制，使深层网络也容易训练？

1.2 核心思想

传统神经网络试图直接学习从输入 x 到输出 $H(x)$ 的复杂映射。但是在普通网络中，如果你堆叠一层无法学习到有效特征的变换（比如某层初始化不好或难训练），这层可能会严重破坏前面提取到的特征，造成性能退化。为了解决这个问题，作者在论文中引入以下设计：




图 1.2: 残差块结构

ResNet 的核心在于将其重写为: $\mathbf{H}(\mathbf{x}) = \mathbf{F}(\mathbf{x}) + \mathbf{x}$, 其中 $\mathbf{F}(\mathbf{x})$ 是需要学习的“残差函数”, 也就是神经网络中每一层进行的映射, 在这里可以认为是某一层对输入的修改建议, 而网络的实际输出是“输入 $\mathbf{x}$ ”与“建议修改 $\mathbf{F}(\mathbf{x})$ ”的叠加。这也就意味着, 网络不是重新创造整个输出, **而是在已有输入的基础上学习如何微调 and 修正**。这种结构通过一个“**shortcut connection**”(捷径连接)实现。

从数学角度来看如果最优的函数其实是恒等映射 (即 $\mathbf{H}(\mathbf{x})=\mathbf{x}$), 普通网络很难学习; 而 ResNet 只需学出 $\mathbf{F}(\mathbf{x})=0$, 也就是最后输出仍为输入的 $\mathbf{x}$ 。通俗一点来解释, 也就是在 ResNet 中, 如果某层“什么也没学到”(也就是 $\mathbf{F}(\mathbf{x})=0$), 那么输出 $\mathbf{y}=\mathbf{x}+\mathbf{F}(\mathbf{x})=\mathbf{x}$, 也就是恒等映射, 网络的输出仍然是前一层的输出, 保持了信息的完整性。这样就提高了神经网络的容错性, **而不是像传统神经网络那样在更深层易丢失之前提取到的特征**, 降低了深层学习的难度, 使得深度学习成为可能。

从另外一个角度来看, 我们可以把这个结构看成是一个电路, 增加的“shortcut connection”就相当于把中间的层给短接了, 中间的层在整个神经网络中的重要性也会降低, 也就是神经网络对于层数的增加不再那么敏感了。

另外, 在反向传播阶段, 如果是传统的神经网络, 可能会由于层数太多, 并且由于这些中间层大多包含激活函数和权重, 梯度会不断被压缩 (小于 1 的乘积), 甚至变成 0, 导致梯度消失, 浅层参数得不到有效更新。而对于 ResNet 来说, 由于我们引入了一个加法, 使得梯度变为:

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \cdot \left(\frac{\partial F(x)}{\partial x} + I \right)$$

通过引入的这个加法求导得到的常量 I , **我们可以避免梯度消失**。

1.3 网络架构设计

Plain Network (普通网络): 普通网络主要参考 VGGNet, 属于没有残差连接的传统 CNN, 使用 3×3 卷积, 为了保持每层的时间复杂度, 遵循两条规则:

- 相同特征图大小的层, 滤波器数量 (也就是通道数) 相同。
- 特征图大小减半时, 滤波器数量加倍 (面积缩小了 (像素少), 但通道变多了, flops 乘积差不多不变)。

并且使用步长为 2 的卷积层直接做下采样 (代替池化层), 在最后使用全局平均池化, 再接一个 1000 类别的全连接层和 softmax 作为分类器。

与 VGG 相比, PlainNet 整体设计更轻量用的滤波器更少, 参数更少, 复杂度低于 VGG 网络。

Residual Network (残差网络): 在普通网络基础上添加跳跃连接:

- 恒等跳跃: 输入输出维度相同时直接相加 (不相同时也可以用 0 填充维度不够的部分, 不增加任何参数)。
- 投影跳跃: 维度不同时使用 1×1 卷积调整。

只要是网络输出尺寸 $\mathbf{F}(\mathbf{x})$ 和 $\mathbf{x}$ 不匹配, 就得使用 stride=2 的 1×1 卷积对 $\mathbf{x}$ 进行“降采样”。




图 1.3: Example network architectures for ImageNet.

左侧 VGG-19: 作为参考基准, 使用大量 3×3 卷积和三层全连接 (FLOPs 约 19.6B);
 中间 PlainNet-34: 与 ResNet 相同的卷积堆叠 (34 层), 但没有 shortcut (FLOPs 仅 3.6B);
 右侧 ResNet-34: 在 PlainNet 基础上加入 shortcut, 即变成残差网络 (FLOPs 仅 3.6B)。

1.4 实验结果与对比分析

1.4.1 18 层和 34 层的普通网络比较

在实验阶段，作者首先比对了评估了 18 层和 34 层的普通网络，利用的是 ImageNet 2012 图像分类数据集，模型在 128 万张训练图像上训练，并在 5 万张验证图像上进行评估，最终结果在 10 万张测试图像上获得，并通过官方测试服务器评估，分别评估了 top-1 和 top-5（比较宽松）错误率。

	plain	ResNet
18 layers	27.94	27.88
34 layers	28.54	25.03

图 1.4: Top-1 error

图 1.4 结果显示，34 层的 PlainNet Top-1 error 验证误差比 18 层的还要高。




图 1.5: Training on ImageNet(plain)

并且在图 1.5 中，可以看到 34 层的网络训练误差也比 18 层高，验证了不是过拟合，而是网络根本就学不好。并且作者说，这种情况应该不是有梯度消失引起的，原因是这些普通网络使用了 BatchNorm，可以确保前向传播的信号有非零方差，并且他们也验证了反向传播的梯度范数是正常的，因此前向和反向的信号都没有消失。

而作者认为，造成这种现象的原因可能是深层 Plain 网络可能存在“**指数级低的收敛速度**”，导致训练误差难以降低。

1.4.2 18 层和 34 层的残差网络比较

接着,作者进行了对于 18 层和 34 层的残差网络的评估比较。在第一次比对实验中,为所有 shortcut 使用了恒等映射,对于维度不一致的地方使用了“零填充”(不会增加任何新的参数),结果显示,34 层的 ResNet 比 18 层的更好(误差低 2.8%),从图 1.6 中也可以看出,34 层的 ResNet 训练误差更低,并且在验证集上也有较好的泛化能力。




图 1.6: Training on ImageNet(ResNet)

除此之外,在图 1.4 中,也可以看到与普通网络相比,34 层的 ResNet 的 Top-1 错误率降低了 3.5%。

另外,由图 1.5 和 1.6 进行对比,作者发现虽然 18 层的 PlainNet 和 ResNet 的准确率差不多,但 18 层的 ResNet 收敛得更快,也就是说明残差网络的优化过程更轻松。

接着,对于输入输出维度不相同,作者采用了投影 shortcut 而不是刚刚的“零填充”恒等映射。

$$y = F(x) + W_s x$$

其中 W_s 代表的是学习得到的变换 (1×1 卷积核)。

然后通过比较了以下三种 A, B, C 三种做法:

- A. 当输入输出维度不一致时,用 0 填充 (zero-padding); 所有 shortcut 都是无参数的。
- B. 仅当输入输出维度不一致时,使用投影 shortcut (1×1 卷积); 其它情况下仍用 identity shortcut。
- C. 所有 shortcut 都使用 projection (即全部加 1×1 卷积)。

model	top-1 err.	top-5 err.
VGG-16 [41]	28.07	9.33
GoogLeNet [44]	-	9.15
PReLU-net [13]	24.27	7.38
plain-34	28.54	10.02
ResNet-34 A	25.03	7.76
ResNet-34 B	24.52	7.46
ResNet-34 C	24.19	7.40
ResNet-50	22.85	6.71
ResNet-101	21.75	6.05
ResNet-152	21.43	5.71

图 1.7: Error rates (% , 10-crop testing) on ImageNet validation

图 1.7 显示，这三种选项的性能都明显优于普通网络：

B 的效果比 A 略好。作者认为原因是：A 中被填 0 的维度根本没有残差学习能力。

C 的性能比 B 稍微好一点，作者认为这是因为 C 引入了很多投影 shortcut 带来的额外参数。

但 A/B/C 之间的差距很小，说明 **投影 shortcut 并不是解决退化问题的关键，关键是“残差连接”的思想**。并且由于 C 引入了更多参数，训练时间更长。

所以作者主张在非必要时使用恒等 shortcut，只有尺寸不一致才用 1×1 卷积，这样能在性能和效率之间取得平衡。

1.4.3 更深的残差网络——瓶颈结构

在之后的实验中，作者设计了**更深的残差网络**，并且提出了一种关键结构设计——**瓶颈结构 (Bottleneck architecture)**。




图 1.8: 瓶颈结构

瓶颈设计 (Bottleneck): 针对更深网络 (如 50/101/152 层), 每个残差块使用 $1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1$ 卷积, 这样设计会比之前的效率高得多。原因是第一个 1×1 卷积将通道数进行了压缩, **所以中间的 3×3 卷积就可以在小通道数下计算**, 最后的 1×1 卷积将通道数恢复原来的维度, **这样就能减少计算量** (如图 1.8 右)。

并且作者说, 对于瓶颈结构来说, **无参数的恒等 shortcut** 尤其重要。如果将图 1.8 右侧的 identity shortcut 换成 projection (带参数的 1×1 卷积), 由于 shortcut 两端连接的是高维空间, 那么时间复杂度和模型大小都会翻倍。

method	top-1 err.	top-5 err.
VGG [41] (ILSVRC'14)	-	8.43 [†]
GoogLeNet [44] (ILSVRC'14)	-	7.89
VGG [41] (v5)	24.4	7.1
PReLU-net [13]	21.59	5.71
BN-inception [16]	21.99	5.81
ResNet-34 B	21.84	5.71
ResNet-34 C	21.53	5.60
ResNet-50	20.74	5.25
ResNet-101	19.87	4.60
ResNet-152	19.38	4.49

图 1.9: single-model

从图 1.7 和 1.9 可以看出, 尽管深度显著增加, 但 ResNet-50、101、152 的准确率都明显高于 ResNet-34。并且 152 层 ResNet 在验证集上的 Top-5 错误率为 **4.49%** (单模型)。

method	top-5 err. (test)
VGG [41] (ILSVRC'14)	7.32
GoogLeNet [44] (ILSVRC'14)	6.66
VGG [41] (v5)	6.8
PReLU-net [13]	4.94
BN-inception [16]	4.82
ResNet (ILSVRC'15)	3.57

图 1.10: ensembles

并且由图 1.10 可以看到, 这个单模型结果已经优于此前所有模型集成 (ensemble) 方法的结果。并最终赢得了 **ILSVRC 2015 的第一名**。

另外基于 CIFAR-10 实验, 也获得了不错的结果, ResNet 在浅层和深层都优于普通网络, 表现出强大的可扩展性。